Analisi Dataset Assessing Mathematics Learning in Higher Education (AMLHE)

Intelligenza Artificiale II

Allegra Berardi (2116628)
Sofia Bruno (2146543)
Simone Manunza (2156783)

Il Dataset AMLHE

Il dataset (AMLHE) raccoglie i risultati di problemi matematici di studenti della scuola superiore provenienti da diversi paesi, Europei e non.

- Dimensione: 9546 istanze di tipo numerico, categorico, binario e testuale
- Feature:
  - Student ID: identificativo del singolo studente
  - Student Country: paese di provenienza
  - Question ID: identificativo della domanda
  - Question Level: difficoltà della domanda (Basic/Advanced)
  - Topic: macro-area del problema
  - Subtopic: sotto-argomento specifico dei topic
  - Keywords: parole chiave associate ai topic
- Target: Type of Answer (1 = corretta, 0 = errata)
- Obiettivo del modello: identificare i pattern che influenzano il successo degli studenti in ambito matematico.

Analisi Esplorativa dei Dati (EDA)

La prima parte dell'EDA affronta un'analisi generale delle domande con i seguenti risultati:

- Numero di domande: 9546
- Percentuale di domande errate: 53,2%
- Percentuale di domande corrette: 46,8%
- Numero di domande "Basic": 7844
- Numero di domande "Advanced": 1702

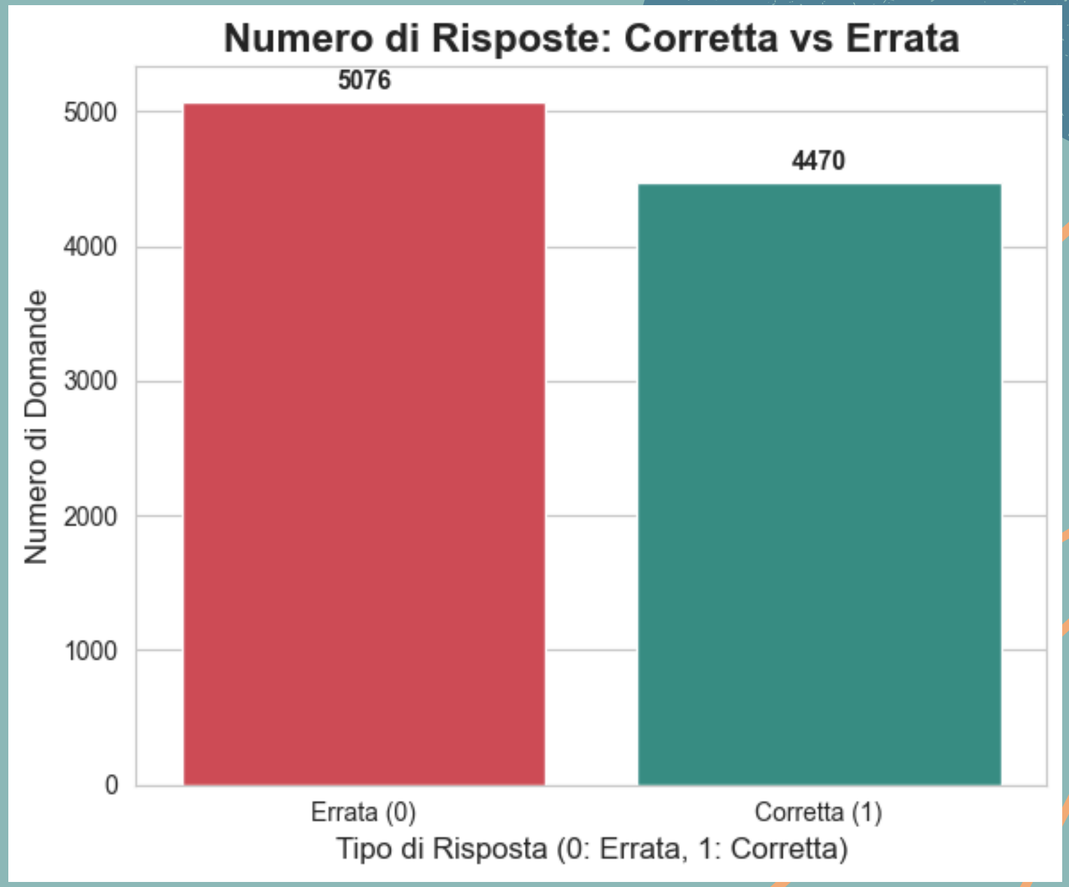

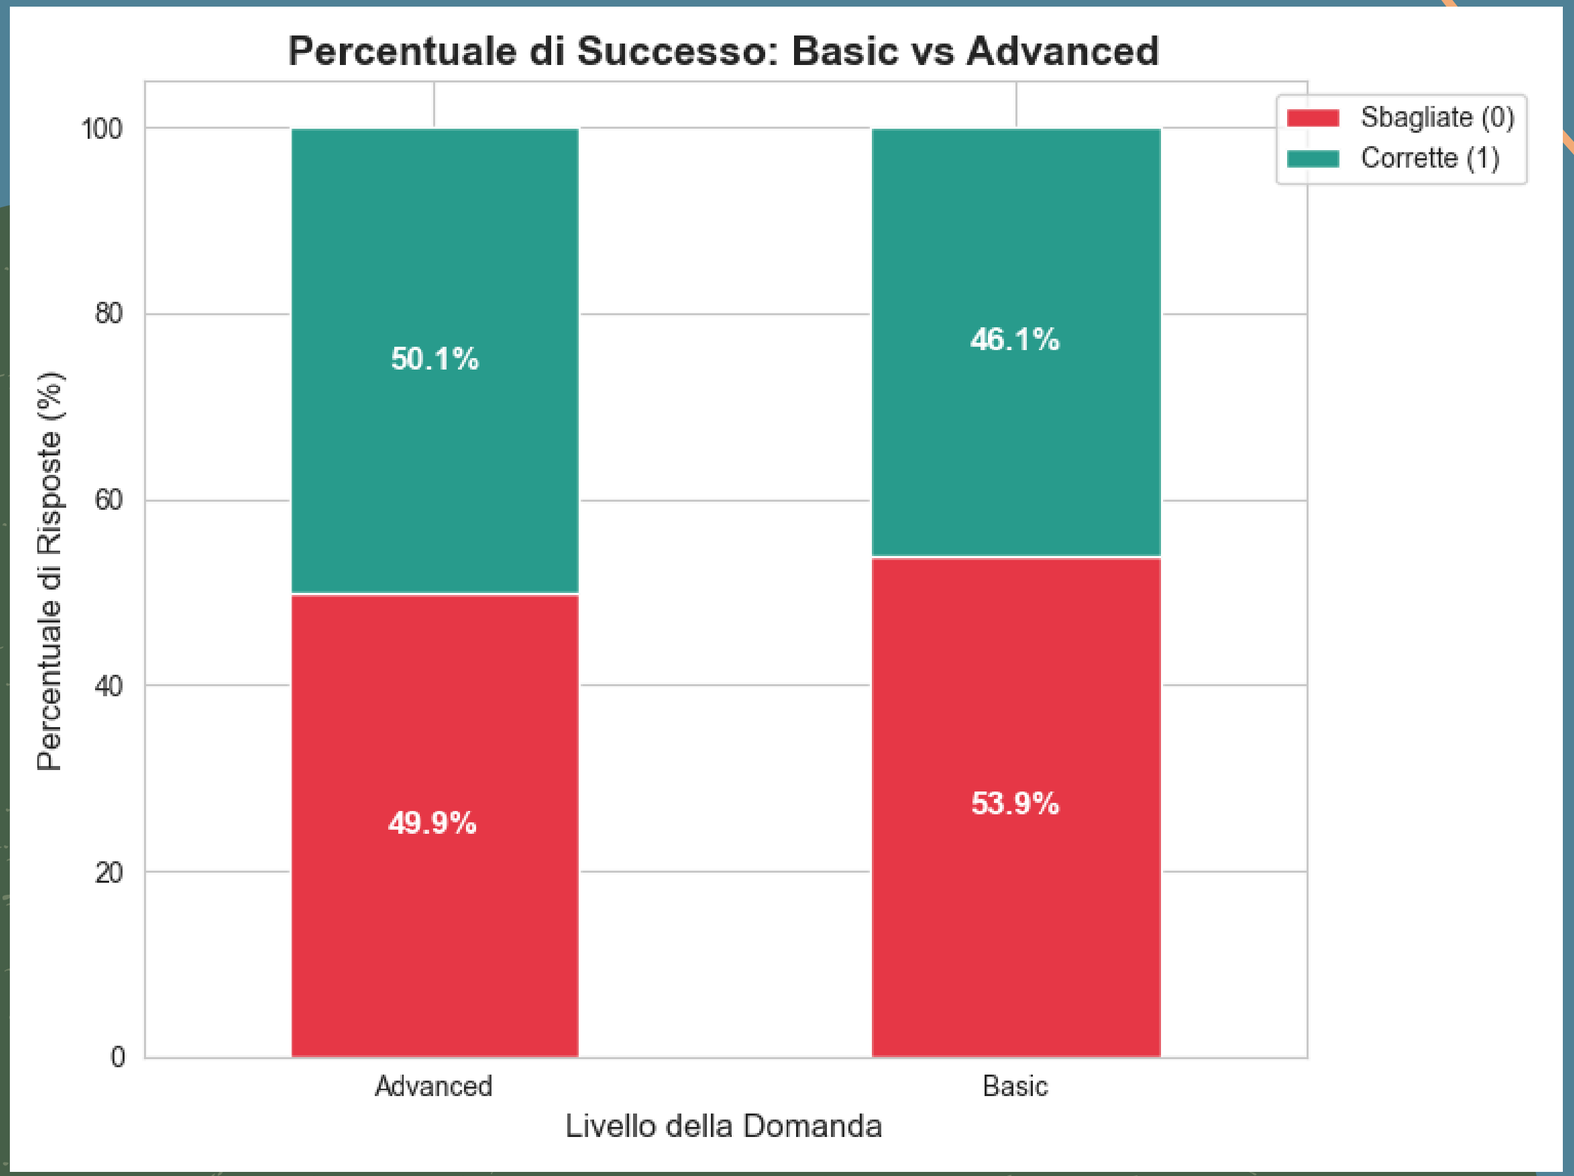
Percentuale di Successo: Basic vs Advanced
Sbagliate (0)
Corrette (1)
Percentuale di Risposte (%)
100
80
60
40
20
0
50.1%
49.9%
46.1%
53.9%
Advanced
Basic
Livello della Domanda

Il grafico mostra le percentuali di risposte corrette per paese. Il paese con il rendimento scolastico migliore è la Slovenia con una percentuale di (68,7%), mentre il paese con il rendimento scolastico più scarso è la Russia con una percentuale di (34,6%).

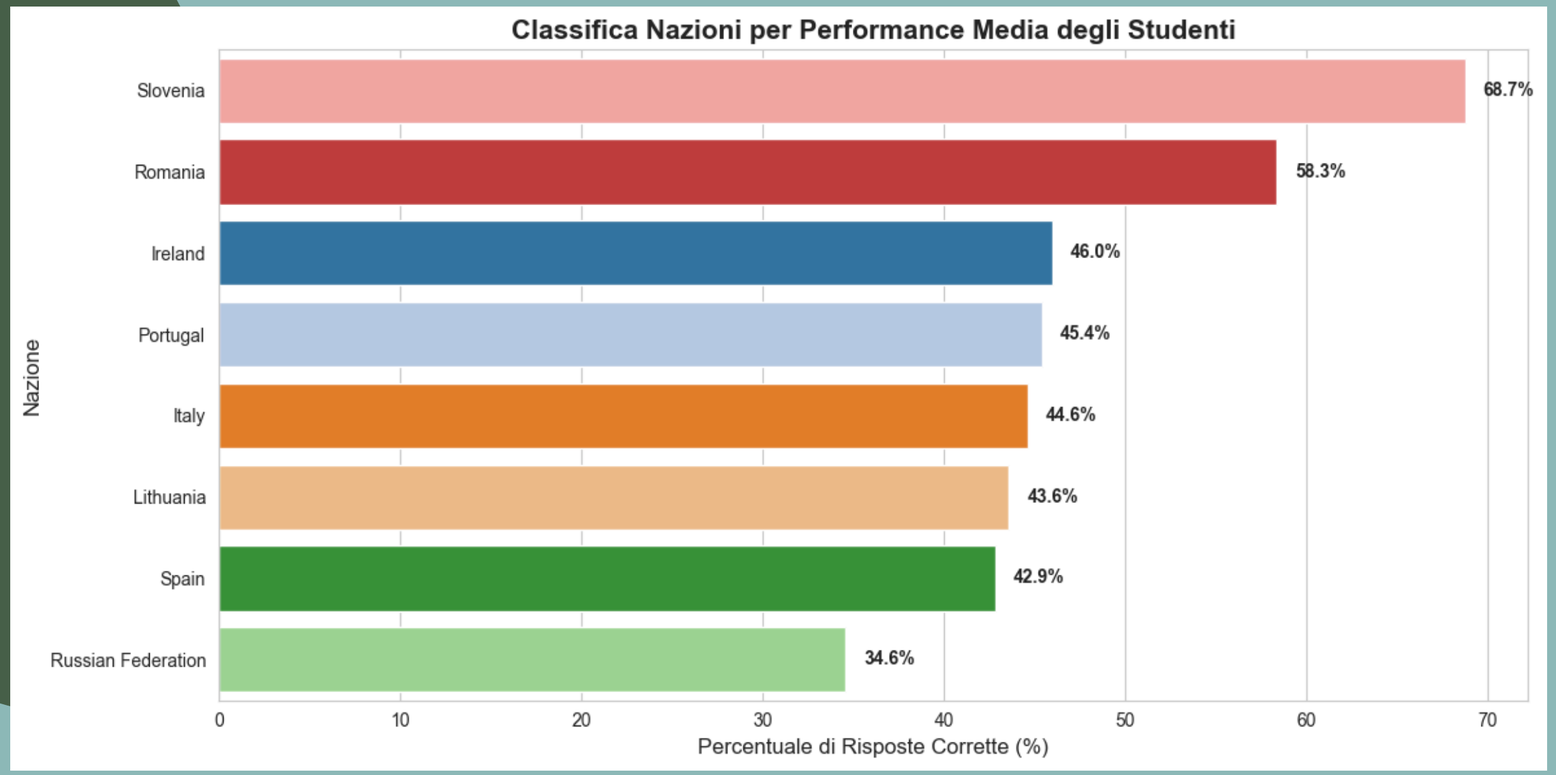

L'analisi sul numero di studenti per nazione, dimostra, però, un bias numerico verso nazioni come Portogallo, Lituania e Italia.

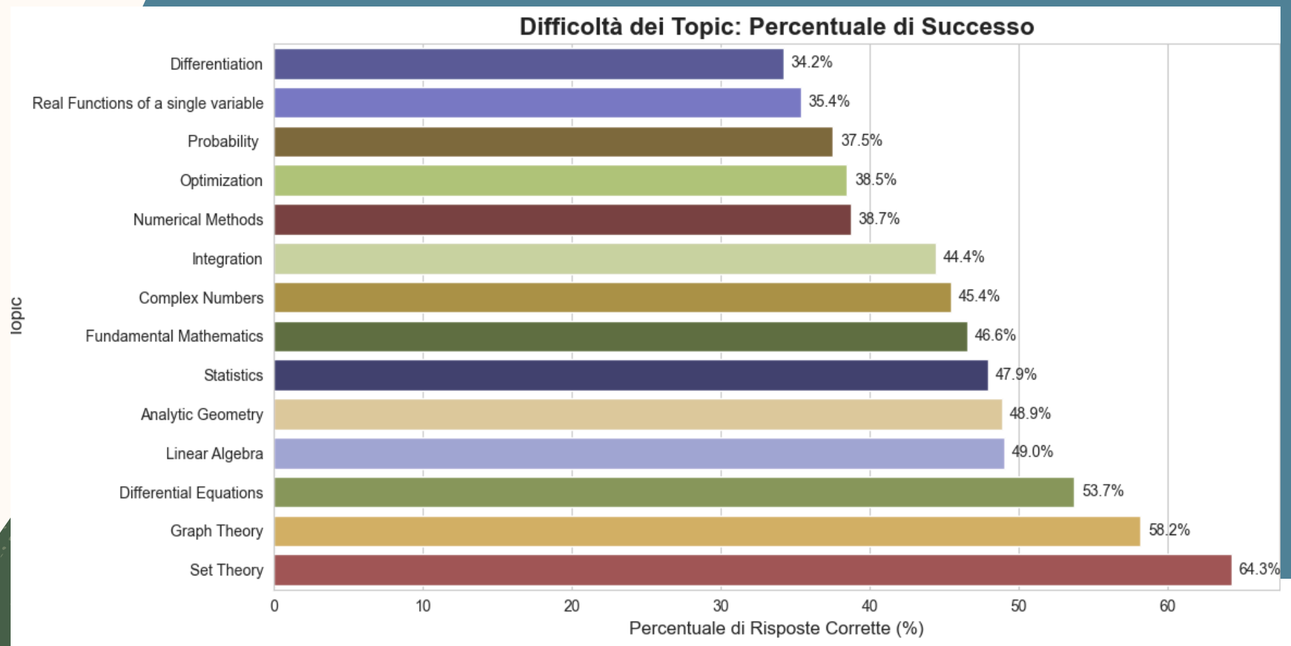
Difficoltà dei Topic: Percentuale di Successo
Differentiation
Real Functions of a single variable
Probability
Optimization
Numerical Methods
Integration
Complex Numbers
Fundamental Mathematics
Statistics
Analytic Geometry
Linear Algebra
Differential Equations
Graph Theory
Set Theory
34.2%
35.4%
37.5%
38.5%
38.7%
44.4%
45.4%
46.6%
47.9%
48.9%
49.0%
53.7%
58.2%
64.3%
Topic
0
10
20
30
40
50
60
Percentuale di Risposte Corrette (%)

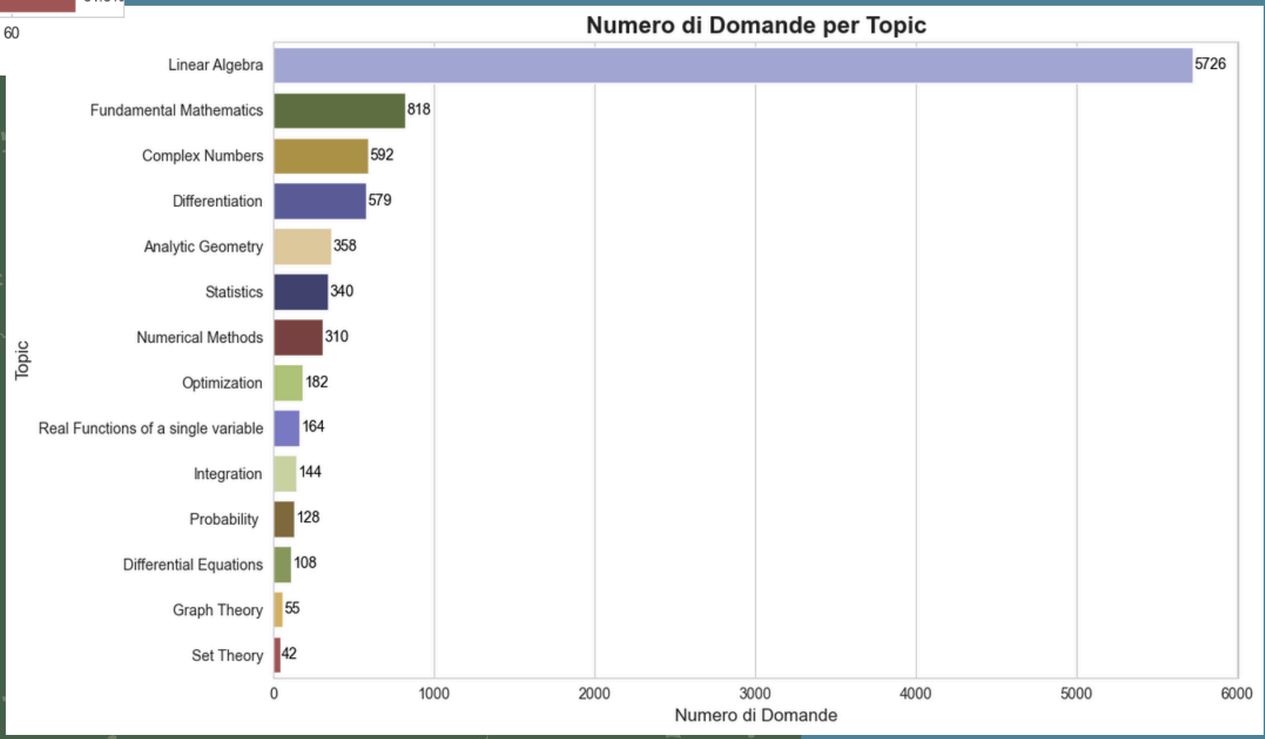
Numero di Domande per Topic
Linear Algebra
Fundamental Mathematics
Complex Numbers
Differentiation
Analytic Geometry
Statistics
Numerical Methods
Optimization
Real Functions of a single variable
Integration
Probability
Differential Equations
Graph Theory
Set Theory
5726
818
592
579
358
340
310
182
164
144
128
108
55
42
Topic
0
1000
2000
3000
4000
5000
6000
Numero di Domande

Risultati EDA

L’analisi esplorativa dei dati mette in luce diversi sbilanciamenti che troviamo nel dataset:

- Numero di Domande Corrette ed Errate
- Numero di Domande Basic e Advanced
- Numero di Studenti per Nazione
- Numero di Domande per Topic

Preprocessing & Feature Engineering

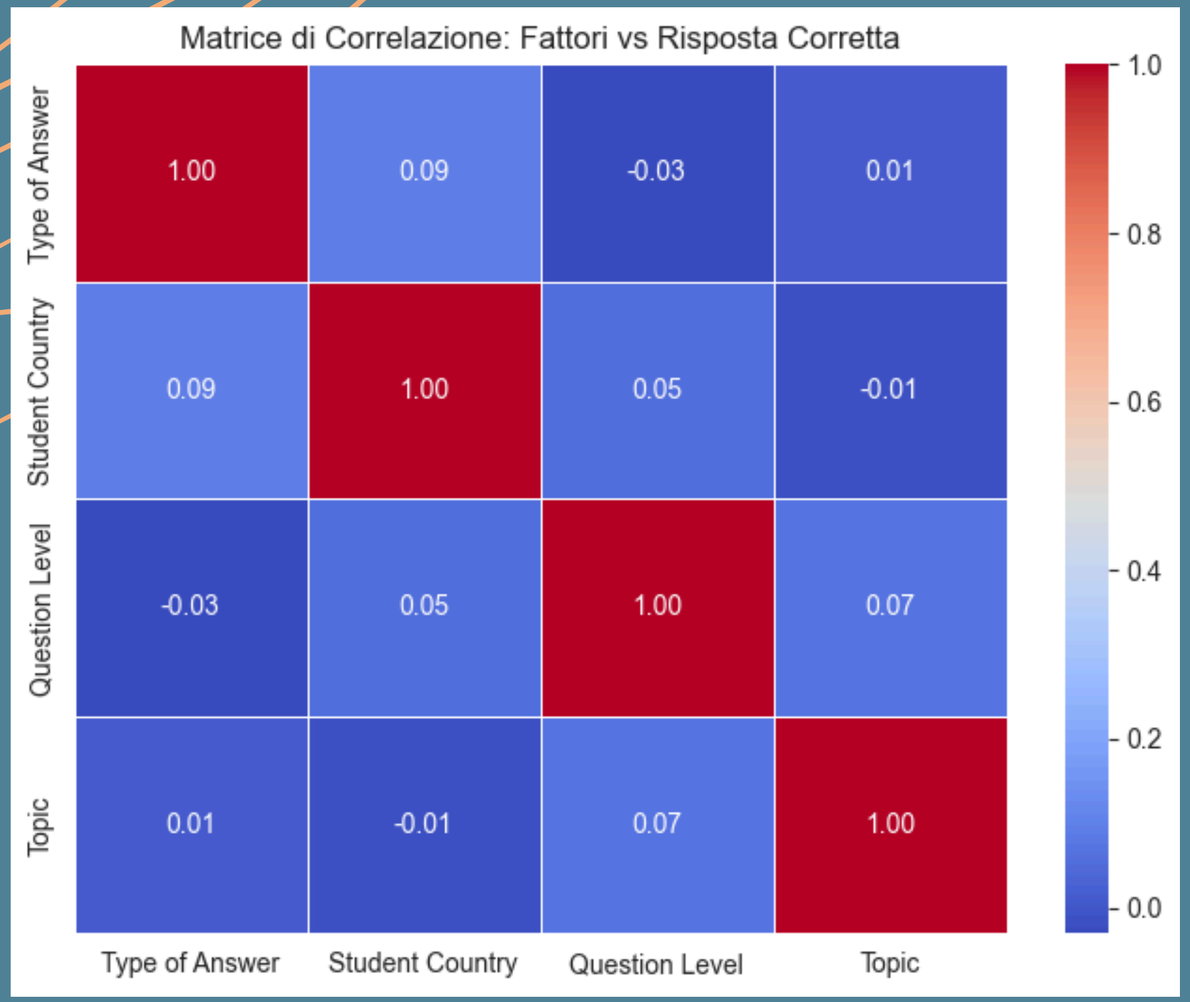

Abbiamo usato Label Econder per generare la matrice di correlazione, NLP e One-Hot Encoding per l'addestramento dei modelli, trasformando i valori testuali in valori numerici.

Metodi e Modelli

Abbiamo addestrato il modello su 80% dei dati e testato la sua capacità di previsione sul restante 20%, usando la Stratificazione, con “stratify=y”, per mantenere la stessa proporzione tra risposte corrette ed errate in entrambi i set.

- Logistic Regression: modello lineare come baseline.

- Random Forest: modello basato su Ensemble Learning per catturare relazioni non lineari tra le variabili.

Metodi e Modelli: Risultati a confronto

Valutazione Random Forest

	precision	recall	f1-score	support
0	0.58	0.73	0.64	1016
1	0.56	0.39	0.46	894
accuracy			0.57	1910
macro avg	0.57	0.56	0.55	1910
weighted avg	0.57	0.57	0.56	1910

Accuratezza Random Forest: 0.5675

Valutazione Logistic Regression

	precision	recall	f1-score	support
0	0.58	0.67	0.62	1016
1	0.55	0.45	0.49	894
accuracy			0.57	1910
macro avg	0.56	0.56	0.56	1910
weighted avg	0.56	0.57	0.56	1910

Accuratezza Logistic Regression: 0.5696

Analisi della Matrice di Confusione

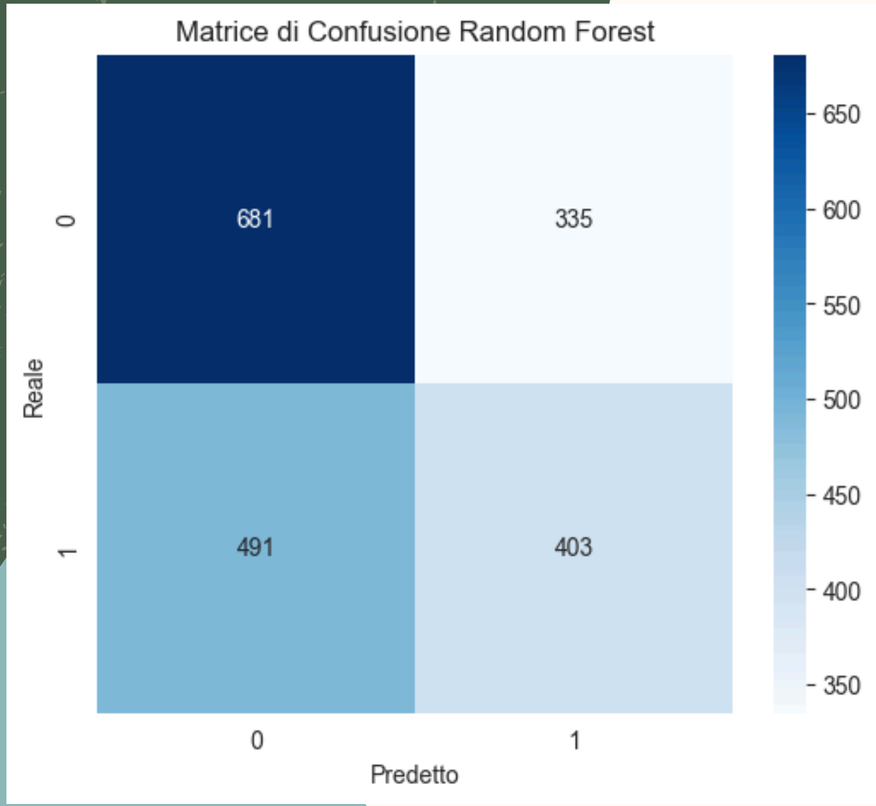

Le matrici di confusione mostrano alti valori sia di Precision che di Recall nel caso di risposta errata. Rivelano un bias che porta il modello a prevedere con più frequenza una risposta errata che corretta, dimostrando una più alta difficoltà (o più bassa F1-Score) per le risposte corrette.

Conclusioni

Abbiamo imparato a trasformare i dati prima di farli analizzare dal modello.

Attraverso i due modelli scelti, abbiamo avviato un confronto che mette in luce, da una parte una maggiore trasparenza e interpretazione, dall'altra un'analisi dei pattern complessi che riguardano i paesi di provenienza, gli argomenti e le difficoltà delle domande.

L'analisi delle matrici di confusione ha rilevato uno sbilanciamento del dataset verso le risposte errate che abitua il modello a fare previsioni troppo approssimate su nuovi dati e a prevedere l'errore anche quando assente.